

项目说明：提示词工程实验

一、项目目标

本项目希望构建一个针对慢性淋巴细胞白血病的提示词工程实验流程，能够根据患者症状描述自动匹配证型和治法，实现症状-证型-治法的全流程自动匹配，具体目标包括：

- 1、多策略探索：尝试不同的大模型提示工程
- 2、性能优化：通过投票机制提升辨证准确性和稳定性
- 3、模型评价：根据测试数据中的预测结果和真实结果的语义相似度判断匹配的准确度

二、不同的提示词工程尝试及结果

本文选取的四种策略分别是（1）Zero-Shot Prompting、（2）增强自检机制（Self-contrast）、（3）Few shot+CoT 和（4）Few-Shot + CoT + Self-Consistency，为了验证哪个结果更好，四次尝试均不修改大语言模型框架，采用 model="ernie-4.5-0.3b"，并且保持

max_completion_tokens 不变。

每次根据计算预测值与真实值在语义向量空间中的余弦相似度，实现对证型和治法匹配准确性的量化评估，该方法避免了传统分类准确率的局限性，能够捕捉中医学术语间的语义关联，为中医自然语言处理任务提供了更为精细的评估手段。

计算证型、治法真实值与预测值的余弦相似度，取平均作为最终分数。

```
def score(predict_zx, predict_zf):
    ZX_score = []
    ZF_score = []
    for i in range(len(predict_zx)):

        zheng_xing_sub = predict_zx[i].strip()
        zheng_xing_gro = ZX[i].strip()
        zhi_fa_sub = predict_zf[i].strip()
        zhi_fa_gro = ZF[i].strip()

        sim_x = calculate_similarity(zheng_xing_sub, zheng_xing_gro)
        sim_f = calculate_similarity(zhi_fa_sub, zhi_fa_gro)

        ZX_score.append(sim_x)
        ZF_score.append(sim_f)

    zx_mean = np.mean(ZX_score) if ZX_score else 0.0
    zf_mean = np.mean(ZF_score) if ZF_score else 0.0

    final_score = ((zx_mean + zf_mean) / 2) * 100 # 百分制
    return final_score
```

```
final_score = score(predict_zx, predict_zf)
print(final_score)
```

(1) Zero-Shot Prompting

Elavis Saravia 提出的基本指令框架包括^[1]：Instruction (必须)：

指令，即你希望模型执行的具体任务。Context (选填)： 背景信息

或者说是上下文信息，这可以引导模型做出更好的反应。Input

Data (选填)： 输入数据，告知模型需要处理的数据。Output

Indicator (选填)： 输出指示器，告知模型我们要输出的类型或格式。

Zero-shot 模型的 prompt 部分没有多余的信息，仅告诉大语言模型充当的角色和需要的输出格式。

```
def call_large_model(symptoms):  
    """  
    调用ERNIE X1大模型进行证型治法生成  
    返回结构化JSON结果  
    """  
    system_prompt = """  
    你是一位经验丰富的中医专家，请根据患者症状描述判断：  
    1. 证型：需符合慢性淋巴细胞白血病中医辨证标准  
    2. 治法：需与证型对应且符合中医治疗原则  
    请用JSON格式输出：{"证型":"","治法":""}  
    """  
  
    messages = [  
        {"role": "system", "content": system_prompt},  
        {"role": "user", "content": f"患者症状: {symptoms}"}  
    ]  
  
    try:  
        response = client.chat.completions.create(  
            model="ernie-4.5-0.3b",  
            messages=messages,  
            max_completion_tokens=512,  
            temperature=0.3,  
            top_p=0.7  
        )
```

在 Zero-shot 策略中，模型的表现很不好：

```
final_score = score(predict_zx, predict_zf)
print(final_score)
```

88.00647502730286

从输出的结果可以看出模型数据有比较大的随意性：

A	B	C	D	E	F
症状 患者男性，身高170cm，体重70kg。 西医诊断为慢性淋巴细胞白血病。 现症见：口中发黏，唾液粘稠，痰涎量多，偶有咯吐、偶有发生、时有胸闷或腹胀，可自行缓解、劳时即乏。舌象可见淡红、齿痕、淡黄、润，脉象为弦脉。	预测证型 脾虚湿盛证	预测治法 健脾化湿	正确证型 痰湿内蕴	正确治法 健脾燥湿，化痰利浊	
患者女性，身高150cm，体重47kg。 西医诊断为慢性淋巴细胞白血病 分期为Rai分期 IV，Binet分期 C。既往史：房颤。 现症见：浅表部位可触及肿块，在3cm以上，质硬，活动度差，或触合成团块状、痰涎量中等，经常有咯吐、时有胸闷或腹胀，可自行缓解、劳时即乏、劳时则气短、苍白或萎黄、偶有发生。舌象可见红、肿大、淡黄、润，脉象为弦细脉。 体格检查发现：颈部淋巴结：肿大；腋下淋巴结：肿大；腹股沟淋巴结：肿大。 备注：咳嗽，脾大，肋下三指。	脾大	健脾益气，化痰散结	痰湿内蕴	健脾燥湿，化痰利浊	
患者女性，身高165cm，体重90kg。 西医诊断为慢性淋巴细胞白血病。 现症见：浅表部位可触及肿块，在3cm以内，质较硬，活动度可、舌暗红，有淤点。舌象可见淡红、淡紫、齿痕、白、润，脉象为数细脉。 体格检查发现：颈部淋巴结：肿大。	脾肾两虚证	健脾益气，补肾填精	痰湿内蕴	健脾燥湿，化痰利浊	
患者男性，身高180cm，体重95kg。 西医诊断为慢性淋巴细胞白血病 分期为Rai分期 0，Binet分期 A。既往史：高血压。 现症见：浅表未触及肿块，但特殊检查可见站位性病变、患者形体肥胖、舌暗红，有淤点、经常汗出，汗出量大。舌象可见淡红、淡紫、肿大、裂纹、白、	脾肾两虚证	健脾益气，补肾填精	脾虚痰湿	健脾益气，化湿祛痰	

(2) 增强自检机制 (Self-contrast)

Zero-Shot Prompting 模型结果存在比较大的随意性，比如大语言模型给出的症状表述比较不规范，存在比较强的直觉思考的现象。

Hagendorff 等人 (2022) 的研究中发现大语言模型同时拥有快思考和慢思考的思维过程^[2]，为了防止大语言出现直觉思考（也就是快思考），本研究改进在提示词工程中增加置信度评估和自评分，要求大语言模型输出包含：证型、治法、理由、置信度、自评分，引入量化评估机制提升模型自省能力。

```
system_prompt = """
你是一位经验丰富并谨慎的中医临床专家。任务：根据患者症状判断【证型】并给出对应【治法】。请严格遵守下面格式与要求：

输出格式（必须为严格的JSON对象，允许包含在```json```代码块中）：
{
  "证型": "短文本（必填）",
  "治法": "短文本（必填）",
  "理由": "不超过40字的简要诊断依据（必填）",
  "置信度": 0.00,    // 一个0-1之间的小数，表示你对该诊断的置信度（必填）
  "自评分": 0       // 按下列评分规则对本次输出打分（0-100整数，必填）
}

评分规则（用于生成自评分）：
- 诊断与慢性淋巴细胞白血病中医辨证标准符合：40分
- 治法与证型对应、符合中医原则：30分
- 理由简洁且包含关键证据（如：脾虚、痰湿、气虚、血瘀等）：20分
- 置信度与自评分一致性（置信度*100 与 自评分差距≤20）：10分

注意：
1) 不要输出内部链式思考（不要输出长篇推理过程）。只给出上面指定的结构化字段和简短理由。
2) 理由应为“诊断依据”的摘要，不超过40字（例如：“脾虚兼湿，舌淡苔白，倦怠腹胀”）。
3) 置信度与自评分是量化提示，目的是促使模型自检；请诚实评估。
4) 如果无法判断，请返回证型为“未知”并把置信度设为0，自评分设为0，理由写“信息不足”。
"""

|
  messages = [
    {"role": "system", "content": system_prompt},
    {"role": "user", "content": f"患者症状: {symptoms}"}
  ]
```

虽然增加了模型的自我检测机制，但是在缺乏外部反馈的情况下，LLM 内在的反思能力是十分不稳定的，LLM 在自我评估时常表现出过度自信（Overconfident）或高度随机性（Inconsistent），即LLM 往往会提供十分顽固或很随机的 feedback，从而导致反思效果

不理想，从结果中可以看出，模型并没有明显的提高，接近 zero-shot 的结果。

```
final_score = score(predict_zx, predict_zf)
print(final_score)
```

88.69835320845209

(3) Few shot+CoT

增加了自评的模型并没有特别明显的改善，说明模型可能缺少一些相关的知识或是一些可以理解的例子，因此在这里我们尝试给大语言一些中医相关的知识，并且告诉大语言模型一些类似的案例，参考 Brown (2020) 提出的 Few-Shot Prompting 的策略^[3]，且要求大语言模型“一步一步分析”（采用 CoT 的策略），Kojima 等人 (2022) 的发现即使在 Zero shot 的情况下，CoT 策略也是有效的，Chain of Thought 的技巧使用起来非常简单，只需要在问题的结尾里放一句 Let's think step by step （让我们一步步地思考），模型输出的答案会更加准确^[4]，在这里我参考 Wei (2022) 等人的工作^[5]，

将 Few-shot 和 CoT 结合起来，在给大模型一些相关案例的同时要求

大模型一步步思考。

```
system_prompt = """
你是一位中医专家，根据慢性淋巴细胞白血病患者症状：
1. 分析证型（一般是四字，如痰湿内蕴，可XX兼XX，如痰湿内蕴兼气虚发热）
2. 对应治法（逗号隔开，如健脾祛湿，燥湿化痰）
### 分析原则：
请根据以下优先级和关键症状进行判断：
**1. 气阴两虚**
- **关键条件**：满足以下条件之一：
  （1）有明显的气虚表现（如：动时即乏、精神疲惫、懒于言语、气短、劳时则气短、口唇色较淡、脉细弱/沉细）
  （2）有明显的阴虚表现（如舌裂纹、失眠/手足热、脉数/细数/滑数、体重下降、小便黄、睡眠不足）
**2. 痰瘀互结**
- **关键条件**：必须同时满足以下两项：
  （1）有痰湿凝聚证据（淋巴结肿大）
  （2）有明确瘀血证据（舌暗红有淤点、舌淡紫）
**3. 脾虚痰湿**
- **关键条件**：必须同时满足以下两项：
  （1）有脾虚表现（如纳差、舌胖大/齿痕）
  （2）有痰湿证据（淋巴结肿大、痰多、口中粘腻）
  （3）但不符合上述气阴两虚或痰瘀互结的标准
**4. 痰湿内蕴**
- **关键条件**：
  （1）有痰湿症状（口中粘腻、痰多）
  （2）但无显著淋巴结肿大，且脾虚症状较轻
  （4）无阴虚、瘀血证据
5. **兼证处理**：
  * 仅在主要证型非常明确，且另一个证型的症状也相当突出时，才使用“兼”。例如，一个典型的“痰湿内蕴”患者，同时有非常严重的“不动即乏”，可
请一步一步分析证型和治法
例子：案例1（痰湿内蕴）：
症状：口中发黏，痰涎量多，劳时即乏。
分析：虽然有“劳时即乏”的轻度气虚，但核心矛盾是“口中发黏、痰多”等痰湿邪气壅盛的表现。舌象也是典型的齿痕、润。所以是实证为主，辨证为“痰湿内
案例2（气阴两虚）：
症状：不动即乏、精神疲惫、懒于言语（严重气虚） + 手足心发热、腰膝酸软、失眠、大便偏硬（严重阴虚）。
分析：这里也有“口中发黏”的湿象，但与严重的气阴两虚症状相比，它是次要的。患者的根本问题是身体的功能和物质基础都严重亏虚了。所以是虚证，辨证
### 输出要求：
1、严格使用以下JSON格式输出：{"证型":"","治法":""}
2、确保“证型”字段中不包含“证”字（例如，输出“脾虚痰湿”，而非“脾虚痰湿证”）。
3、不要有任何其他内容。

```

在这种策略下，模型相比之前改善了不少，从 88 提升到 94，说明这

种策略是有效的：

```
[36]: final_score = score(predict_zx, predict_zf)
print(final_score)

94.62822372032404
```

（4）Few-Shot + CoT + Self-Consistency

在上一个版本的输出中模型预测已经有比较大的改善，但是通过多次输出会发现，模型表现不够稳定，因此再次改进模型，在 Few shot+CoT 的基础上加上 Self-Consistency 策略。

Self-Consistency 策略是对 Chain of Thought 的一个补充，对推理结果进行自我校对，让模型生成多种推理路径，并最终选择最一致的答案，Self-Consistency 利用“复杂推理问题通常存在多种不同思考方式”这一特点，生成多样的推理路径有效减少错误答案的影响，提高了最终答案的准确性与模型的鲁棒性，它让模型生成多个思维链，然后让模型进行投票，取大多数答案的作为最终结果^[6]。在本研究中多次独立调用大模型（7 次），收集证型和治法投票结果，统计频次选择最高票结果。


```

def predict2(symptom, num_votes=7):
    """
    使用多次投票策略预测证型和治法
    """
    votes_zx = [] # 存储证型投票
    votes_zf = [] # 存储治法投票
    for i in range(num_votes):
        try:
            model_result = call_large_model_3(symptom)
            votes_zx.append(model_result['证型'])
            votes_zf.append(model_result['治法'])
            time.sleep(0.2) # 避免过快请求
        except Exception as e:
            print(f"第{i + 1}次投票失败: {str(e)}")
            continue
    # 选择最频繁出现的证型
    if votes_zx:
        final_zx = max(set(votes_zx), key=votes_zx.count)
    else:
        final_zx = "未知"
    # 选择最频繁出现的治法
    if votes_zf:
        final_zf = max(set(votes_zf), key=votes_zf.count)
    else:
        final_zf = "待定"
    print(f"症状: {symptom}")
    print(f"证型投票结果: {dict(zip(*np.unique(votes_zx, return_counts=True)))}")
    print(f"治法投票结果: {dict(zip(*np.unique(votes_zf, return_counts=True)))}")
    print(f"最终结果 - 证型: {final_zx}, 治法: {final_zf}")
    print("-" * 50)
    return final_zx, final_zf

```

从输出结果中可以看出，和上一次（仅包含 Few shot+CoT 的策略）的输出结果是一样的，但是如果多次输出具有更高的稳定性，可以改善模型随机回答的概率。

```

[15]: final_score = score(predict_zx, predict_zf)
      print(final_score)

```

```

94.62822372032404

```

这里展示了前几条的预测结果，可以看出和第一次（Zero-shot）的结果相比，模型的回答已经比较接近正确回答：

					度
(1) Zero-Shot	仅提供基	较差，输			
	础指令与	出随意性		弱，	
	格式，无	大，不符	低	缺乏	简单
	示例或额	合专业规		推理	
	外引导	范		过程	
(2) 增强自检 (Self-contrast)	引入置信			中	
	度评估与	无明显改		等，	
	自评分，	善，模型		有自	
	强制模型	自评存在	低	评分	中等
	进行慢思	过度自信		数但	
(3) Few-Shot + CoT	考与自我	或随机性		可靠	
	反思	问题		性差	
	提供少量	显著提	中等，	强，	中等
	中医示	升，从 88	单次输	具备	

(4) Few-Shot + CoT + Self-Consistency	例，并要求模型进行逐步推理	提升至94，输出更符合专业逻辑	出质量	清晰	较高
			高但多	的逐	
			次运行	步推	
			间可能	理链	
			有波动	条	
				最	
				强，	
			高，投	兼具	
			票机制	推理	
			有效降	链与	
	在(3)基础上，生成多个推理路径并行投票集成	与(3)单次最佳结果一致，但多次运行稳定性显著提高	低随机	多路	
			误差	径一	
				致性	
				验证	

综合以上对比分析，我最终选择了策略(4)：Few-Shot + CoT +

Self-Consistency 作为本研究的最终模型方案。主要基于以下几点原因：

因：

- 在保持高准确性的前提下，实现了最优的稳定性：策略(3) (Few-Shot + CoT) 已显著提升了模型的推理能力和输出准确性，证明了提供领域示例和引导逐步思考的有效性。然而，对于需要可靠部署的应用场景，单次输出的波动性仍是一个风险。策略(4)通过引入 Self-Consistency 机制，对同一问题生成多个独立的推理路径并进行多数投票，本质上是一种集成学习方法。这显著降低了模型因随机性而产生错误输出的概率，增加了最终答案在多次运行中的高度一致性，从而获得了最高的综合稳定性。
- 增强了结果的可靠性与可信度：从业务的角度看，提示词工程讲究“理法方药”的连贯性与一致性。Self-Consistency 机制要求模型从多个角度“思考”同一问题，只有当多数推理路径指向同一证型和治法时，该结果才会被采纳。这种“多路径验证”过程模拟了专家会诊或重复检验的思想，使得最终输出不再是单一的、可能受偶然因素影响的

判断，而是经过内部交叉验证的、更可信的结论。

- 平衡了性能与复杂度的关系：尽管策略(4)的实现复杂度高于前三种（需要多次调用模型并进行结果聚合），但其带来的性能收益是显著的。相比于追求极端简化但效果不佳的 Zero-Shot，或引入了不稳定自检环节的策略(2)，策略(4)以可接受的额外计算成本（7次独立调用），换取了准确性与稳定性的双重保障。在资源允许的情况下，这是一种性价比较高的优化方案。

四、提交结果

最终，本研究选择策略(4) Few-Shot + CoT + Self-Consistency 作为最终模型，是在本实验条件下，综合考虑准确性、稳定性、可靠性及可解释性后的最优解。它有效地将领域知识（Few-Shot）、结构化推理（CoT）和自我一致性（Self-Consistency）相结合，提供了一个较为鲁棒和有效的提示工程实践方案。

在 prompt 中通过 Few-shot 和 CoT 模型告知大模型分析的路径和方

法：：

```
system_prompt = """
你是一位中医专家，根据慢性淋巴细胞白血病患者症状：
1. 分析证型（一般是四字，如痰湿内蕴，可XX兼XX，如痰湿内蕴兼气虚发热）
2. 对应治法（逗号隔开，如健脾祛湿，燥湿化痰）
### 分析原则：
请根据以下优先级和关键症状进行判断：
**1. 气阴两虚**
- **关键条件**：满足以下条件之一：
  （1）有明显的气虚表现（如：动时即乏、精神疲惫、懒于言语、气短、劳时则气短、口唇色较淡、脉细弱/沉细）
  （2）有明确的阴虚表现（如舌裂纹、失眠/手足热、脉数/细数/滑数、体重下降、小便黄、睡眠不足）
**2. 痰瘀互结**
- **关键条件**：必须同时满足以下两项：
  （1）有痰湿凝聚证据（淋巴结肿大）
  （2）有明确瘀血证据（舌暗红有淤点、舌淡紫）
**3. 脾虚痰湿**
- **关键条件**：必须同时满足以下两项：
  （1）有脾虚表现（如纳差、舌胖大/齿痕）
  （2）有痰湿证据（淋巴结肿大、痰多、口中粘腻）
  （3）但不符合上述气阴两虚或痰瘀互结的标准
**4. 痰湿内蕴**
- **关键条件**：
  （1）有痰湿症状（口中粘腻、痰多）
  （2）但无显著淋巴结肿大，且脾虚症状较轻
  （4）无阴虚、瘀血证据
5.  **兼证处理**：
  * 仅在主要证型非常明确，且另一个证型的症状也相当突出时，才使用“兼”。例如，一个典型的“痰湿内蕴”患者，同时有非常严重的“不动即乏”，可
  请一步一步分析证型和治法
例子：案例1（痰湿内蕴）：
症状：口中发黏，痰涎量多，劳时即乏。
分析：虽然有“劳时即乏”的轻度气虚，但核心矛盾是“口中发黏、痰多”等痰湿邪气壅盛的表现。舌象也是典型的齿痕、润。所以是实证为主，辨证为“痰湿内：
案例2（气阴两虚）：
症状：不动即乏、精神疲惫、懒于言语（严重气虚） + 手足心发热、腰膝酸软、失眠、大便偏硬（严重阴虚）。
分析：这里也有“口中发黏”的湿象，但与严重的气阴两虚症状相比，它是次要的。患者的根本问题是身体的功能和物质基础都严重亏虚了。所以是虚证，辨证
### 输出要求：
1、严格使用以下JSON格式输出：{"证型":"","治法":""}
2、确保“证型”字段中不包含“证”字（例如，输出“脾虚痰湿”，而非“脾虚痰湿证”）。

```

再通过多次调用实现 Self-consistency：

```
def predict(symptom, num_votes=7):
    """
    使用多次投票策略预测证型和治法
    """
    votes_zx = [] # 存储证型投票
    votes_zf = [] # 存储治法投票
    for i in range(num_votes):
        try:
            model_result = call_large_model_3(symptom)
            votes_zx.append(model_result['证型'])
            votes_zf.append(model_result['治法'])
            time.sleep(0.2) # 避免过快请求
        except Exception as e:
            print(f"第{i + 1}次投票失败: {str(e)}")
            continue
    # 选择最频繁出现的证型
    if votes_zx:
        final_zx = max(set(votes_zx), key=votes_zx.count)
    else:
        final_zx = "未知"
    # 选择最频繁出现的治法
    if votes_zf:
        final_zf = max(set(votes_zf), key=votes_zf.count)
    else:
        final_zf = "待定"
    print(f"症状: {symptom}")
    print(f"证型投票结果: {dict(zip(*np.unique(votes_zx, return_counts=True)))}")
    print(f"治法投票结果: {dict(zip(*np.unique(votes_zf, return_counts=True)))}")
    print(f"最终结果 - 证型: {final_zx}, 治法: {final_zf}")
    print("-" * 50)
    return final_zx, final_zf
```

最终提交的预测结果如下，可以看出具有较高的准确性：

测试详情

测试点	状态	时长	结果
测试结果分数	✓	15s	测试成功，得分为 92.96155384131536

确定

¹⁾ <https://github.com/dair-ai/Prompt-Engineering-Guide/tree/main/guides>

²⁾ Hagendorff T, Fabi S, Kosinski M. Thinking fast and slow in large language models[J]. arXiv preprint arXiv:2212.05206, 2022.

³⁾ Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[J]. Advances in neural information processing systems, 2020, 33: 1877-1901.

⁴ Kojima T, Gu S S, Reid M, et al. Large language models are zero-shot reasoners[J]. Advances in neural information processing systems, 2022, 35: 22199-22213.

⁵ Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in neural information processing systems, 2022, 35: 24824-24837.

⁶ Wang X, Wei J, Schuurmans D, et al. Self-consistency improves chain of thought reasoning in language models[J]. arXiv preprint arXiv:2203.11171, 2022.